



Фундаментальная и прикладная
лингвистика

НИУ ВШЭ

Нижний Новгород
2026

Мультиязыковое исследование лингвистических особенностей заголовков постов в социальных сетях (на примере русскоязычного сегмента Pinterest и китайской платформы Xiaohongshu)

Попова Ксения | Федина Анна

Научный руководитель:

к.ф.н., старший научный
сотрудник Центра языка и мозга
НИУ ВШЭ-НН
А. Ю. Хоменко

Соруководитель:

приглашенный преподаватель
департамента фундаментальной
и прикладной лингвистики
А. М. Зинина




ЦЕЛЬ РАБОТЫ

выявить и сравнить лингвистические особенности заголовков постов для визуально-ориентированных платформ Pinterest и Xiaohongshu

МЕДИАДИСКУРС –

совокупность процессов и продуктов речевой деятельности в сфере массовой коммуникации, формируемая взаимодействием экстралингвистических факторов

(Добросклонская, 2006:20–23)





ЗАДАЧИ

1. Изучить научно-теоретическую базу: понятия «корпус», «лингвистическая разметка», «медиадискурс», «социальные сети»;
2. **Создать универсальную схему разметки речевого материала** для заголовков постов выбранных социальных сетей;
3. **Разметить материал** по схеме двумя способами: мануальным и с помощью программного обеспечения;
4. Выявить отличительные лингвистические особенности для каждого языка

МЕТОДЫ

1. Анализ и синтез;
2. Классификация;
3. Автоматизация морфологической разметки на базе Python 3.11;
4. Количественный контент-анализ;
5. Дискурс-анализ;
6. Методы математической статистики (коэффициент ранговой корреляции Спирмена, U-критерий Манна-Уитни с поправкой Беньямини-Хохберга);
7. Контрастивный анализ

«контрастивное описание языков может осуществляться на различных уровнях языковой системы: фонологическом, морфологическом, лексическом, фразеологическом, синтаксическом..»

(Стернин, 2006:195)



ЭМПИРИЧЕСКИЙ МАТЕРИАЛ

- **Китайский сегмент (ZH, Xiaohongshu):** датасет [Data Mining Xiaohongshu](#), платформа Kaggle (2021 г.)
- **Русский сегмент (RU, Pinterest):** парсинг заголовков с помощью Apify и n8n (2021 г.)
- **Количество заголовков:** RU – 100, ZH – 100
- **Объем в токенах:** RU – 885, ZH – 1065
- **Метрика сопоставимости:** IPM (instances per million tokens)

КОРПУС –

«большой, представленный в машиночитаемом формате, унифицированный, структурированный, размеченный массив языковых данных»

(Захаров, Богданова, 2013:5)

*Автоматическая обработка табличных данных: загрузка, очистка, фильтрация и агрегация данных, работа с датафреймами осуществлялась на базе Python-библиотеки **Pandas**

Работа с массивами, вычисления, частотный анализ (IPM) – библиотека **Numpy

GitHub





ПРОТОКОЛ РАЗМЕТКИ ЗАГОЛОВКОВ

БЛОК	СОДЕРЖАНИЕ
0. Метаданные	id, поисковые слова, текст заголовка, дата, платформа, язык, длина заголовка
1. Графика и орфография	повтор букв, капитализация, пунктуация, эмодзи (8 функций), наличие хэштегов, смешение кодов, конструкции с цифрами
2. Фонетика	звукоподражания, созвучия и их подвиды
3. Морфология	преобладающая часть речи, модель «прил. + сущ.», глагольные формы (1 лицо, императив), превосходная степень
4. Лексика и семантика	стилистически маркированная лексика, заимствования, оценочность, неологизмы, аббревиатуры и др.
5. Синтаксис	тип предложения (структура, цель высказывания), экспрессивный синтаксис (парцелляция, сегментация, асиндетон и др.), риторический вопрос
6. Прагматика	коммуникативные стратегии, персонализация, интертекстуальность





КОЭФФИЦИЕНТ РАНГОВОЙ КОРРЕЛЯЦИИ СПИРМЕНА

Общая корреляция Спирмена по всем 75 признакам составила $r = 0.702$, что свидетельствует о **высокой** силе связи между сегментами

Диапазон значений $ r $	Теснота (сила) корреляционной связи
0.1–0.3	слабая
0.3–0.5	умеренная
0.5–0.7	заметная
0.7–0.9	высокая
0.9–0.99	весьма высокая

Таблица 1. Шкала Чеддока





Для блока 1.3 («Эмотиконы») была выявлена **высокая** сила связи ($r = 0.830$)


номинативная функция эмодзи


RU: Вкуснейший торт за 15 минут 🍰 ✨
ZH: iPhone13 香 📱 蓝牙迁移数据 («iPhone 13 – вкусняшка
Перенос данных по Bluetooth»)

Для блока 4 («Лексико-семантический уровень») была выявлена **заметная** сила связи ($r = 0.599$)

интенсификаторы

RU: 10 безумно богатых звёзд, которые выросли в нищете
ZH: 驾考经验分享 绝对干货满满 («Опыт сдачи экзамена
на права – абсолютно полезная информация»)





Для блока 5 («Синтаксический уровень») была выявлена **высокая** сила связи ($r = 0.763$)

общность иерархии предложений


повествовательное > вопросительное > побудительное

Для блока 6 («Прагматический уровень») была выявлена **высокая** сила связи ($r = 0.843$)

стратегия привлечения внимания

RU: *Топ-бренды с WB, которые взорвали интернет: не упустите шанс быть в тренде!* 🌟👗

ZH: 救命 SOS 广州首家螺蛳粉牛杂火锅!! 香哭了 («Спасите! В Гуанчжоу первый ресторан с лапшой с улитками и субпродуктами!! Наплакалась от вкусноты»)





U-критерий Манна-Уитни с поправкой Беньямини-Хохберга

RU (Pinterest)	ZH (Xiaohongshu)	
модель «прил. + сущ.» ($p_{adj} < 0,0001$)	интернет-сленг ($p_{adj} = 0,00008$)	повтор восклицательных знаков ($p_{adj} = 0,00942$)
нейтральная лексика ($p_{adj} < 0,0001$)	англицизмы ($p_{adj} = 0,00011$)	сочетание иероглифов и английских слов ($p_{adj} = 0,02527$)
стратегия информирования ($p_{adj} < 0,0001$)	сленг ($p_{adj} = 0,00095$)	личное обращение ($p_{adj} = 0,04019$)
СПП ($p_{adj} = 0,00053$)	разделительная функция эмодзи ($p_{adj} = 0,00199$)	глагольные формы 1-го лица ед. ч. ($p_{adj} = 0,04653$)
форма вида n X-ов, которые... ($p_{adj} = 0,01615$)	простые предложения ($p_{adj} = 0,00728$)	стратегия привлечение внимания ($p_{adj} = 0,00603$)
форма вида n Y-х X-ов ($p_{adj} = 0,01878$)	оценочность ($p_{adj} = 0,02227$)	




МОРФОЛОГИЧЕСКАЯ РАЗМЕТКА

RU: доминирование имен существительных
*Визуализации Успеха в Карьере и Достижения
Целей в Работе*

ZH: преобладание имен существительных и
ГЛАГОЛОВ

私藏☀️ 6家高颜值童趣儿童房软装好物分享❤️
(«Личная подборка 6 магазинов с красивыми и
забавными товарами для детской комнаты»);


广州入秋啦! 穿新鞋出门结果下雨了, 嘻嘻
(«В Гуанчжоу наступила осень! Надела новые
туфли, вышла из дома, а в итоге пошел дождь,
хи-хи»)




СИНТАКСИЧЕСКАЯ РАЗМЕТКА

По цели высказывания в RU и ZH преобладают повествовательные предложения

Блок 5.2: Типы предложений по цели высказывания (IPM)



Блок 5.1: Типы предложений по структуре (IPM)



По структуре преобладают:
простые, номинативные, бессоюзные предложения (RU)
простые, номинативные, неполные предложения (ZH)

СИМВОЛ-РАЗДЕЛИТЕЛЬ КАК ОСОБЕННОСТЬ

Символы « | » и « / » при внешне одинаковой реализации несут различные прагматические функции:

- **Тегирование:** механическое дублирование ключевых слов без синтаксической связи; функция сводится к повышению кликабельности

RU: Собака | милый пес | песик | красивая собака | питомец | любимый питомец;

ZH: 宿舍平价沙发椅|宿舍好物|懒人沙发椅 – «Недорогое кресло для общежития | Полезные вещи для общежития | Кресло-мешок»);

- **Сегментация / конструкция топик-комментарий:** вынесение именительного темы в начало

RU: приём экспрессивного синтаксиса (Гардеробная капсула | Забирайте файл по ссылке);

ZH: воспроизведение типичной в китайском языке конструкции (读书|每天五分钟, 一起阅读育儿书籍  – «Чтение | Пять минут в день, читаем книги о воспитании вместе »)

- **Уточнение:** введение дополнительной информации через уточняющие члены

RU: Планы на неделю: как правильно оформить шаблон и расписание дел | femmida.ru;

ZH: 最宝藏阅读APP / 每天一小时培养阅读好 – «Самое ценное приложение для чтения | Один час в день для хорошей привычки чтения»)



ФАКТОР 1. ТИПОЛОГИЯ ЯЗЫКА

RU: относительное преобладание сложных предложений – следствие флективного строя;

ZH: относительное преобладание неполных конструкций, отсутствие СПП и ССП – следствие изолирующего строя

RU: атрибутивная модель «прил. + сущ.» как словосочетание;

ZH: прилагательное выступает качественным сказуемым без вспомогательной связки для акцента на предмете

RU: ассимилированные англицизмы – язык осваивает заимствование;

ZH: транслингвизм как следствие отсутствия флективной системы

ZH: весь фонетический блок специфичен исключительно для китайского языка, звукоподражания иероглифами и цифрами воспроизводят звуковой рисунок устного восклицания

RU: 20 фраз, которые заставят вашего ребенка вас слушаться – СПП

ZH: 不想穿职业装呜呜呜~ («Не хочу носить деловую одежду, [звуки плача] ~») – неполное

RU: Идеальный тропический отдых

ZH: 国庆活动之后数据惨的厉害 («После праздничных мероприятий данные просто ужасающие»)

RU: тренд, бренд, чек-лист

ZH: 获offer («получить оффер»); in广州 («в Гуанчжоу»), 最宝藏阅读APP («самое сокровенное приложение для чтения»)

1) 兔子咬坏了我的长数据线 5555 [wǔ wǔ wǔ] («Кролик перегрыз мой длинный кабель-зарядку [звуки плача]»);

2) 呜呜呜 [wǔ wǔ wǔ] 有无六级网课阅读推荐啊 («[звуки плача], есть ли рекомендации по чтению для экзамена?»)

ФАКТОР 2. АРХИТЕКТУРА ПЛАТФОРМЫ

Pinterest формировался как инструмент коллекционирования идей → тяготение к номинативной стратегии, информационно-нейтральному регистру; Xiaohongshu формировалась как пространство аутентичной потребительской рекомендации → доминирование самопрезентации, оценочности

Побуждение к действию значимо преобладает в ZH через FOMO-конструкции; в RU – мягкий призыв через глаголы в повелительном наклонении

Специфический сленг рекомендательного ZH контента (сленг блогосферы) маркирует принадлежность к сообществу платформы

Прецедентная ситуация только в ZH: культурная и алгоритмическая стратегия продвижения; платформенные алгоритмы чувствительны к ключевым словам актуальных событий

RU: *Гид по винтажным магазинам: 11 мест в Москве.*

Диета для спортсменов для сжигания жира: меню на день.

ZH: *考教编终于过了...经验分享! («Наконец-то сдала экзамен для учителей... делюсь опытом!») – самопрезентация*
📍 广州新店 🍵 茶餐厅界天花板 茗茗冰室 (Новое заведение в Гуанчжоу: потолок в категории чайных ресторанов) – оценка

RU: Учи английские фразы с нуля!

ZH: *看完就能用的恋爱实战经验, 不看可能会亏捏*
(«Прочитаешь – сразу применишь практический опыт в отношениях, не прочитаешь – упустишь свое»)

ZH: *探店 («обзор заведений»); 干货 («полезный контент»); 同款 («точно такой же, как у знаменитости») – в постах на тему обзоров материальных вещей*

ZH: *佛系珠海旅游 / 3天2 夜国庆黄金周人均1k !*

(«Расслабленный туризм в Чжухай: 3 дня 2 ночи в Золотую неделю – 1000 юаней на человека!»)

ФАКТОР 3. СОЦИОКУЛЬТУРНЫЙ ПРОФИЛЬ АУДИТОРИИ

RU: воспроизводит модель контента для широкой и социально неоднородной аудитории;

ZH: нарратив личного преодоления, горизонтальный обмен опытом отражают специфику аудитории – молодых городских жителей в условиях высококонкурентного рынка труда¹

RU: 1) 7 базовых вещей, которые должны быть у каждой девушки. 2) Педагогические заметки: сообщество для педагогов. 3) Как создать свой бренд одежды с нуля | Советы начинающим производству.

ZH: 1) 0经验获字节运营offer!! («Получила оффер в ByteDance с нулем опыта!!»).

2) 6个月双非逆袭985!!419分考研经验贴来啦 («За 6 месяцев из провинциального вуза штурмом взял 985-й!! Пост об опыте поступления в магистратуру: 419 баллов»)

Провокация универсальна, но тематика расходится:

RU – когнитивный диссонанс;

ZH – острые социальные тревоги молодёжи (возрастная дискриминация, классовое неравенство)

RU: Алла Пугачева назвала себя единственной звездой Союза и России.

ZH: 为啥35岁比较危险, 按理说应该是经验丰富 («Почему 35 лет – опасный возраст, хотя по логике это должен быть пик карьерного опыта?»)

RU: адресация к читателю через формы личных и притяжательных местоимений

ZH: разнообразие форм личного обращения

RU: Как создать распорядок дня, который **вы** будете выполнять? Эстетик тумбочка для **твоей** rOOM.

ZH: 你 («ты»); 大家 («все»); 我们 («ребята»); 职场人 («работники»)

ZH: глагольные формы 1-го лица значимо чаще, личный опыт – центральный аргумент доверия

ZH: 发现我学了两年的英语全是垃圾 («Обнаружила, (что) я два года учила плохой английский»)

¹ Zhao Y. Assessment and Optimization of Social Media Marketing Strategies: A Case Study of Xiaohongshu. – SciTePress, 2024. – P. 680



ЛИНГВИСТИЧЕСКИЕ ОСОБЕННОСТИ ВНЕ ПРОТОКОЛА

RU (Pinterest)

- Фразеологизмы (*с нуля, своими руками*) привлекают широкую аудиторию, гарантируя доступность контента;
- Диминутивы (*песик, тортик, кирпичиков*) выстраивают доверие с аудиторией;
- Прием анафоры (*Твоя жизнь – твоя уникальная помада*);
- Репрезентация словосочетания через зависимое слово – экономия слов в заголовке (*Изучаем английский в ТГ*);
- Асиндетон без знаков препинания между однородными членами (*Электронная коммерция динамик аудио плакат баннер*) для привлечения алгоритмов и увеличения охвата поисковых запросов

ZH (Xiaohongshu)

- Используются традиционные китайские кавычки 「」 / 『』 , кавычки для названий произведений 《》 , а также разные виды скобок 【】 / [] ;
- Декоративные символы (тильда ~) – визуальные маркеры тональности, придающее высказыванию легкий, дружелюбный или игривый тон (今天的护肤分享来啦~ – «Сегодня делюсь своим уходом за кожей ~»);
- Употребление диалектизмов вместо литературных форм (为啥 / 为什么 – «почему»), что делает текст более неформальным;
- Модальные частицы (呀, 哎, 哦, 捏) передают субъективное отношение автора, придавая заголовку дружелюбный оттенок;
- Уменьшительно-ласкательный оттенок через замену лексемы на основе фонетического совпадения с диалектной формой (有木有 вместо 有没有 («так или не так?»))



ОСНОВНАЯ БИБЛИОГРАФИЯ

1. Добросклонская, Т. Г. Медиадискурс как объект лингвистики и межкультурной коммуникации / Т. Г. Добросклонская // М. : Вестник Московского университета. Серия 10. Журналистика. – 2006. – № 2. – С. 20–33.
2. Захаров, В. П. Корпусная лингвистика : учебник для студентов направления «Лингвистика» / В. П. Захаров, С. Ю. Богданова. – 2-е изд., перераб. и доп. – СПб. : СПбГУ, 2013. – 234 с.
3. Стернин, И. А. Понятие контрастивного анализа и методика контрастивного описания / И. А. Стернин // М. : «Восток-Запад». – 2006. – 206 с.
4. Zhao Y. Assessment and Optimization of Social Media Marketing Strategies: A Case Study of Xiaohongshu // Proceedings of the 1st International Conference on Engineering Management, Information Technology and Intelligence. – SciTePress, 2024. – P. 679–684. – DOI: 10.5220/001296830000045

СПАСИБО ЗА ВНИМАНИЕ!

